

Análise da Saúde Pública Brasileira usando Inteligência Artificial

Grupo 2 - FEA.dev

Projeto: Mapeamento de Clusters e Detecção de Anomalias usando dados do SUS

Data: Fevereiro/2026

1. Introdução e Contexto

O Brasil possui 5.570 municípios com realidades desiguais. A gestão tradicional de saúde pública, baseada em médias estaduais, falha ao ignorar que cidades ricas podem ter gestão ineficiente e cidades pobres podem ser referências em atenção básica.

1.1. Problema

Identificar padrões de eficiência e vulnerabilidade que não são visíveis em análises geográficas simples e detectar cidades anômalas que fogem de algum padrão estatístico esperado.

1.2. Objetivo

Desenvolver uma aplicação de Inteligência Artificial capaz de:

1. **Clusterizar** os municípios em grupos de semelhança (não por região, mas por indicadores).
2. **Detectar Anomalias** usando Deep Learning para apontar possíveis fraudes ou erros de dados.
3. **Visualizar** os resultados em um Dashboard interativo.

2. Metodologia (Pipeline de Dados)

2.1. Engenharia de Dados

Os dados foram coletados de fontes governamentais oficiais (DATASUS e IBGE) abrangendo indicadores de **Economia, Demografia, Mortalidade e Eficiência Hospitalar**.

- **Fontes:** Sistema de Informações sobre Mortalidade (SIM), Nascidos Vivos (SINASC) e Internações Hospitalares (SIH).
- **Tratamento:** Limpeza de valores nulos, normalização de nomes de municípios e criação de indicadores calculados (ex: *Taxa de Internações por Condições Sensíveis à Atenção Primária - ICSAP*).

2.2. Modelagem: Machine Learning (Clustering)

Utilizamos o algoritmo **K-Means** para segmentar o Brasil. O número ideal de clusters ($k=4$) foi definido pelo método do Cotovelo (Elbow Method).

Definição dos Perfis Encontrados:

- **Cluster 0 - Eficiente:** Indicadores equilibrados e boa eficiência de gastos.
- **Cluster 1 - Crise de Gestão:** Cidades com alta taxa de internações evitáveis (ICSAP), indicando falha na atenção básica.
- **Cluster 2 - Riqueza Desequilibrada:** PIB alto, mas com índices de violência ou mortalidade acima do esperado para a renda.
- **Cluster 3 - Vulnerável :** Baixo PIB, alta dependência do SUS e indicadores de saúde críticos.

2.3. Modelagem: Deep Learning (Anomalias)


Implementamos um **Autoencoder** (Rede Neural Artificial) usando TensorFlow.

- **Lógica:** A rede aprendeu a "comprimir" e "reconstruir" os dados dos municípios "normais".
- **Detecção:** Municípios que a rede não conseguiu reconstruir bem (alto *Erro de Reconstrução*) foram marcados como anomalias matemáticas. Isso aponta para cidades com comportamento atípico.

3. Resultados e Análises

3.1. Panorama Nacional (Mapa de Clusters)

Os 4 Brasis da Saúde Pública




3.2. Casos extremos

Surgem casos de borda, principalmente em municípios pequenos. Por exemplo, municípios com taxa de mortalidade infantil igual a 0 ou municípios pouco populosos levam a um aumento desproporcional de algumas métricas. Isso impacta diretamente no cluster em que são alocados. Uma possível solução a esse problema é a agregação por um período maior de tempo. Um exemplo é o município de Mineiros do Tietê - SP, com população de 11230 habitantes e taxa de mortalidade infantil igual a 0 para o período considerado, ou Oscar Bressane - SP com população de 2470 habitantes e taxa de mortalidade infantil de 66.66 óbitos por mil nascidos (considerado extremamente elevado).

4. Produto Final: Dashboard

Para garantir a aplicabilidade do projeto, desenvolvemos um Data App utilizando a biblioteca Streamlit. A ferramenta permite filtrar dados por estado, comparar municípios com a média de seus clusters e visualizar o um panorama da saúde municipal. Link:

<https://grupo2-teste1-dev.streamlit.app/>



5. Conclusão e Próximos Passos

Melhorias Futuras:

Como melhorias futuras, pode-se elaborar um pipeline de ETL automático dos dados, via schedule no Git Actions, por exemplo. Dessa forma, o dashboard encontraria-se em constante atualização. Pode-se, também, ampliar as bases de dados utilizadas, buscando informações como escolaridade e saneamento básico. Espera-se que essa adição aumente o R^2 . Por fim, pode-se estruturar uma geração automática de relatórios em formato pdf para melhor leitura.

6. Referências e Bibliografia

- **Linguagem:** Python 3.11
- **Machine Learning:** Scikit-Learn (K-Means), TensorFlow (Autoencoders).
- **Visualização:** Plotly, Streamlit, Geopandas.
- **Fontes de Dados:** DATASUS (OpenDataSUS) e IBGE (Sidra).